

会話データからの感情分析

最終発表

1班

長濱 志歩

越塚 毅

坂上 太一

小滝 遼

北原 優江

原田 暁生

藤澤 夏帆

目次

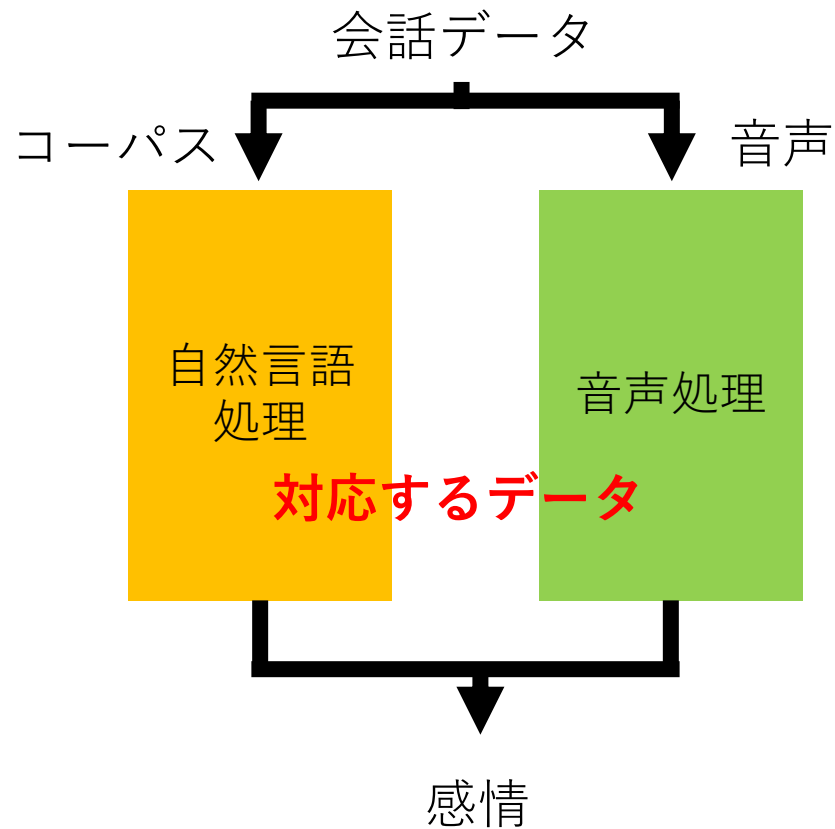
1. プロジェクト課題の目的
2. 中間発表からの変更点
3. 音声処理
 - 3-1. 特徴量について
 - 3-2. 実験(データの説明)
 - 3-3. 実験結果①
 - 3-4. 実験結果②(Dataset1)
 - 3-5. 特徴量の重要度
 - 3-6. 考察
4. 自然言語処理
 - 4-1. 単語分散表現を用いる手法
 - 4-2. 文章分散表現を求める手法
 - 4-3. 深層学習を用いる手法
 - 4-4. 実験(データの説明)
 - 4-5. 実験結果
 - 4-6. 考察
5. まとめ

1. プロジェクト課題の目的

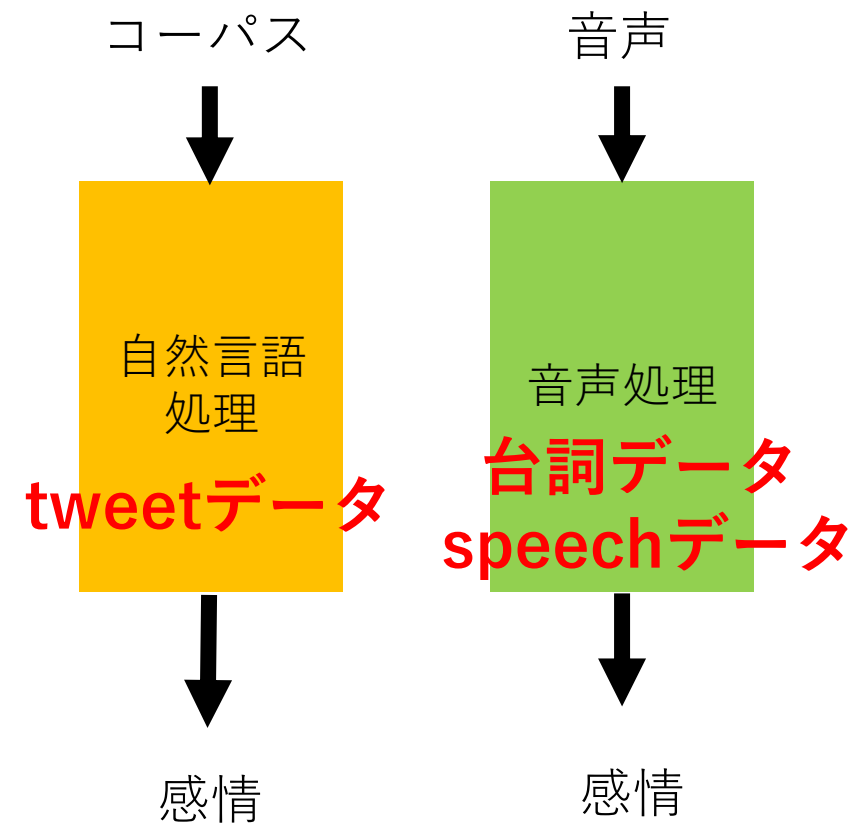
- 音声処理の手法を学ぶ
- 統計的自然言語処理の手法を学ぶ
- 機械学習の手法を学ぶ

2. 中間発表からの変更点

中間発表での構想



変更後



3. 音声処理

- 3-1. 特徴量について
- 3-2. 実験(データの説明)
- 3-3. 実験結果①
- 3-4. 実験結果②
- 3-5. 特徴量の重要度
- 3-5. 考察

3-1. 特徴量について

- スペクトル包絡（低次のメルケプストラム）
人間の声道の特性を表す.
メルケプストラムは低周波数領域を細かくサンプリング.
- デルタメルケプストラム
メルケプストラムの時間変化の微分.動的変化を表す.
- パワー
音量を表す.

3. 音声処理

3-1. 特徴量について

3-2. 実験(データの説明)

3-3. 実験結果①

3-4. 実験結果②

3-5. 特徴量の重要度

3-5. 考察

3-2. 実験



- [Dataset1] 4感情ラベル付きセリフ集読み上げデータ（自作）
 - サンプル数: 100
 - ラベルの付け方: 班員全員でラベル付け
 - 音声データの作り方: ラベルを元に班員が読み上げ
 - 感情: 喜び, 怒り, 悲しみ, ニュートラル
- [Dataset2] 8感情ラベル付きスピーチデータ (RAVDESS)
 - サンプル数: 1440
 - 感情: neutral, calm, happy, sad, angry, fearful, disgust, surprised

3. 音声処理


- 3-1. 特徴量について
- 3-2. 実験(データの説明)
- 3-3. 実験結果①
- 3-4. 実験結果②
- 3-5. 特徴量の重要度
- 3-5. 考察

3-3. 実験結果①

- Dataset1に対し, スペクトル包絡に主成分分析を適用.





先行研究 [庄子, 安藤 2016] の結果



Dataset1の結果

3-3. 実験結果①


- Dataset1に対し, スペクトル包絡に主成分分析を適用.



第5主成分

第4主成分

先行研究 [庄子,安藤 2016] の結果



第5主成分

第4主成分

Dataset1の結果

3. 音声処理

- 3-1. 特徴量について
- 3-2. 実験(データの説明)
- 3-3. 実験結果①
- 3-4. 実験結果②
- 3-5. 特徴量の重要度
- 3-5. 考察

3-4. 実験結果② (Dataset1)

バリデーション手法 : leave-one-out, 評価指標 : accuracy

	線形カーネルSVM	ガウシアンカーネルSVM
100 Samples	0.32	0.41
800 Samples	0.33	0.32

800 Samples はノイズを加える等で拡張をしたデータ

3-4. 実験結果② (Dataset2)

バリデーション手法：stratified 6-fold, 評価指標：accuracy

線形カーネルSVM	ガウシアンカーネル SVM	MLP(2~4 Layers)
0.64	0.60	0.67

3. 音声処理

- 3-1. 特徴量について
- 3-2. 実験(データの説明)
- 3-3. 実験結果①
- 3-4. 実験結果②
- 3-5. 特徴量の重要度
- 3-5. 考察

3-5. 特徴量の重要度


- Permutation Importance

特徴量の列をシャッフルして、
ベースラインからどれだけ精度が落ちるか

緑色のエラーバーは、精度の下り幅が
正規分布に従うと仮定した場合の
95%信頼区間

ベースラインからの
精度差

Permutation Importance



3. 音声処理

- 3-1. 特徴量について
- 3-2. 実験(データの説明)
- 3-3. 実験結果①
- 3-4. 実験結果②
- 3-5. 特徴量の重要度
- 3-5. 考察

3-6. 考察

- Dataset1のスペクトル包絡に対する主成分分析の結果が期待する結果とならなかった。
→ データ数が少なく、本来の低次元空間を求められなかった。
- Permutation Importanceの結果は、Powerが最も精度が落ちた。
→ 音声からの感情解析では、Powerが重要な特徴量である。

4. 自然言語処理

4-1. 単語分散表現を用いる手法

4-2. 文章分散表現を求める手法

4-3. 深層学習を用いる手法

4-4. 実験(データの説明)

4-5. 実験結果

4-6. 考察

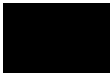
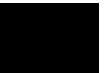
4-1. 単語分散表現を用いる手法

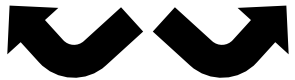
Step1. 単語分散表現の獲得

□ Word2vec [Mikolov et al. 2013]

□ Fasttext [P.Bojanowski et al. 2016]

Skip-Gramモデル

今日 は  混ん  から しんどい



予測

2層のNNを用いて推定.

低次元高密度ベクトル

Subword model による精度向上

$\mathcal{D}_{\text{word}} = \{\text{word の文字 N-gram, Prefix, Suffix 等}\}$

$$V(\text{word}) = \sum_{w \in \mathcal{D}_{\text{word}}} V(w) \quad , \quad V(\cdot) : \text{分散表現}$$

[良] 見出し語化で対応できてない部分を補える

[悪] 関係ない単語が関連付けられる可能性

4-1. 単語分散表現を用いる手法

Step2-1. 単語分散表現から文章分散表現へ

SWEM (Simple Word-Embedding-Based Model) [D Shen et al. 2018]

□ SWEM-aver / SWEM-max

□ SWEM-hier


単語分散表現

私				
は				
とても				
嬉しい				

Average/ Max

私はとても				
嬉しい				

単語分散表現

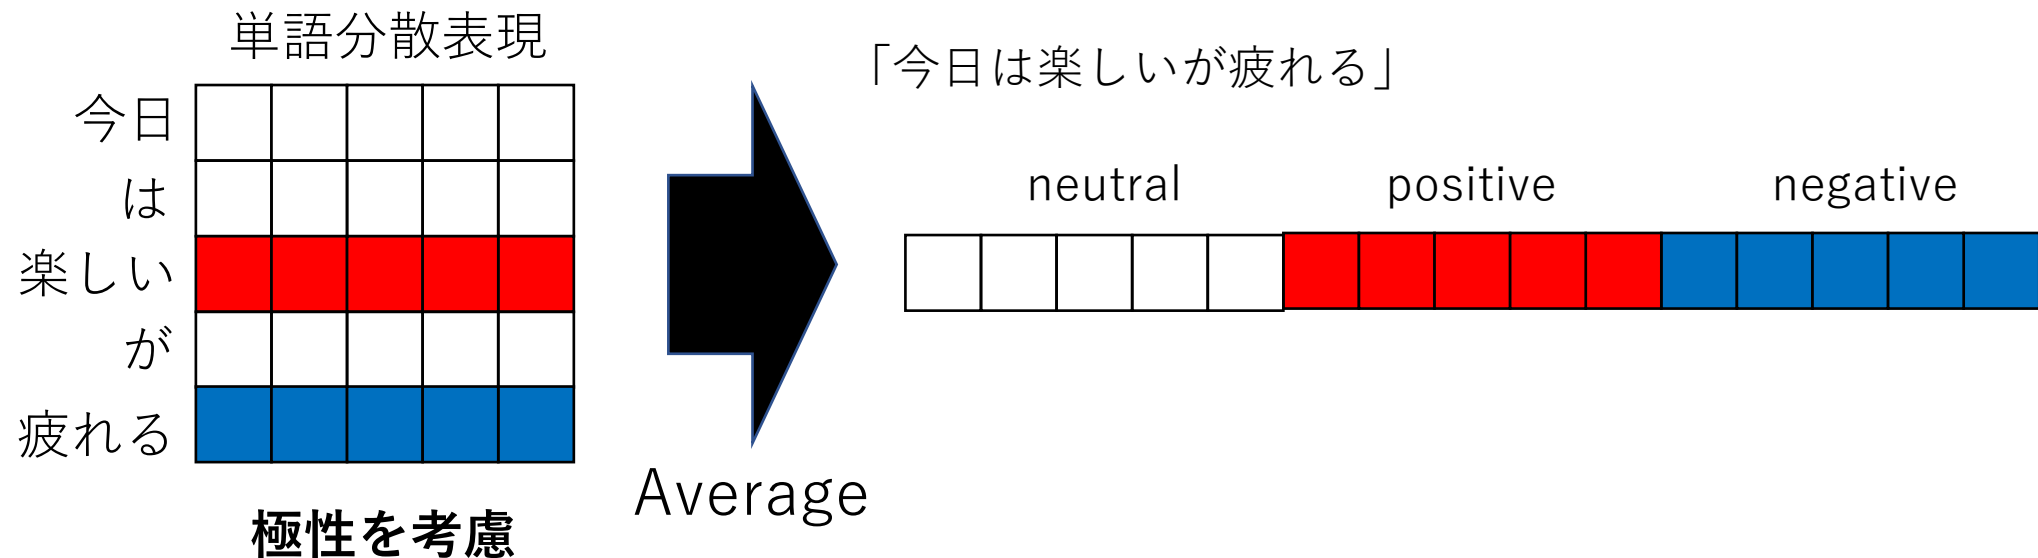


私はとても				
嬉しい				

4-1. 単語分散表現を用いる手法

Step2-2. 単語分散表現から文章分散表現へ

極性辞書を用いる手法 (Sentiment Document Vector)



感情に関する単語が埋もれないようにする

参考: TWE [Y Liu et al. 2015], SCDV [D. Mekala et al. 2017]

4. 自然言語処理

4-1. 単語分散表現を用いる手法

4-2. 文章分散表現を求める手法

4-3. 深層学習を用いる手法

4-4. 実験(データの説明)

4-5. 実験結果

4-6. 考察

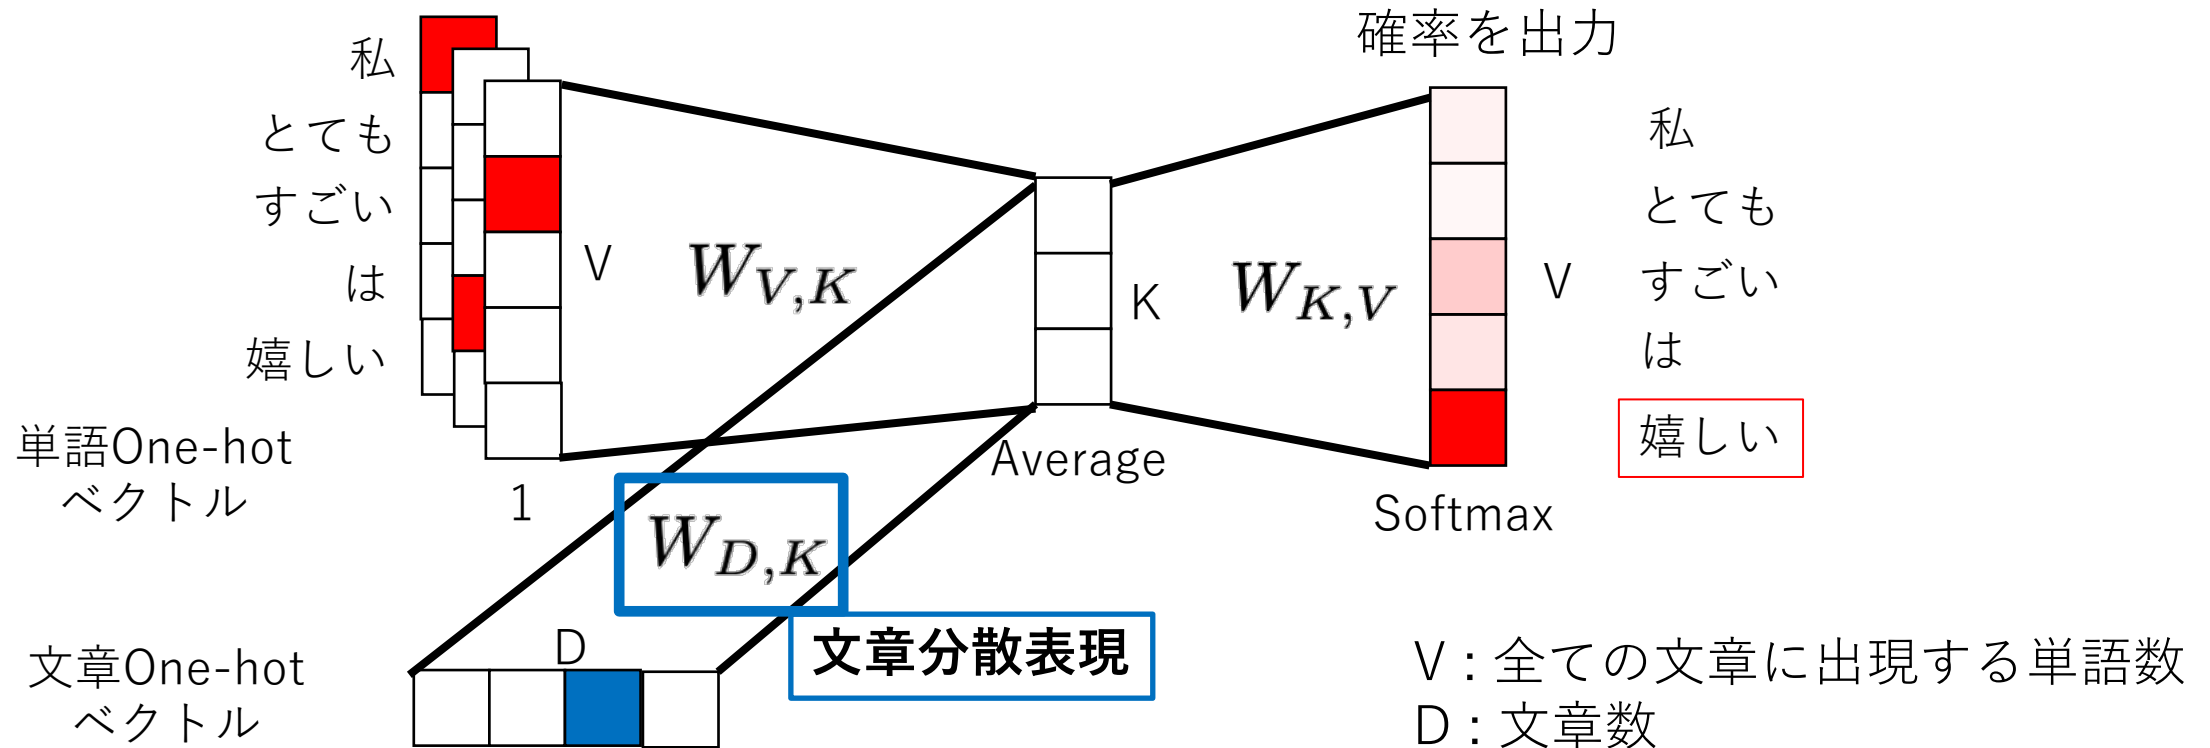
4-2. 文章分散表現を直接求める手法

□ Doc2vec (PV-DM/PV-DBOW) [Quoc V. Le 2014]

私はとても



PV-DM

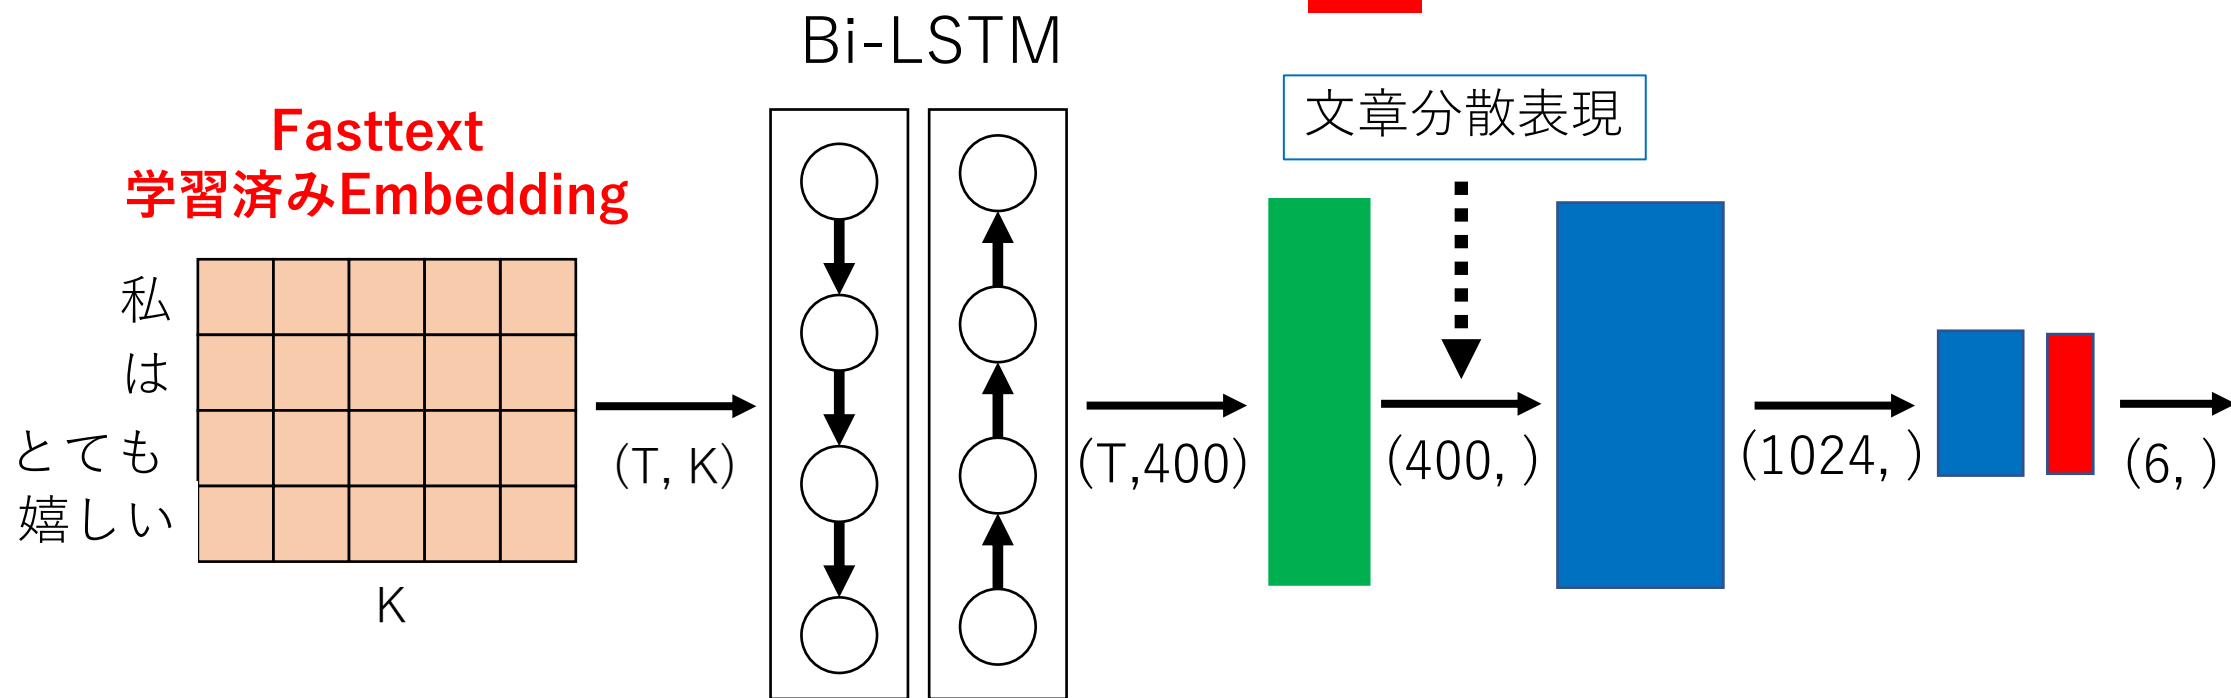
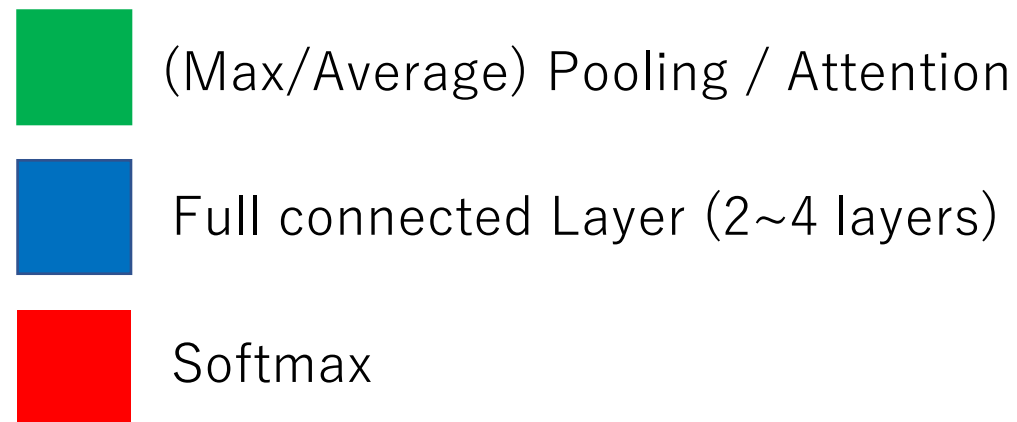


4. 自然言語処理

- 4-1. 単語分散表現を用いる手法
- 4-2. 文章分散表現を求める手法
- 4-3. 深層学習を用いる手法
- 4-4. 実験(データの説明)
- 4-5. 実験結果
- 4-6. 考察

4-3. 深層学習を用いる手法

□ LSTM, Bi-LSTM, GRU



全ての時刻の出力($t = 1, \dots, T$)を返す

語順を考慮した学習を行う

4. 自然言語処理



- 4-1. 単語分散表現を用いる手法
- 4-2. 文章分散表現を求める手法
- 4-3. 深層学習を用いる手法
- 4-4. 実験(データの説明)
- 4-5. 実験結果
- 4-6. 考察

4-4. 実験

- Twitterの5感情ラベル付きコーパス(自作)

■ サンプル数: 約10000ツイート

■ ラベルの付け方: 班員2名でラベルづけ



4. 自然言語処理

- 4-1. 単語分散表現を用いる手法
- 4-2. 文章分散表現を求める手法
- 4-3. 深層学習を用いる手法
- 4-4. 実験(データの説明)
- 4-5. 実験結果
- 4-6. 考察

4-5. 実験結果(カウトベース)

適合率と再現率を考慮した
Accuracy

バリデーション手法：stratified 6-fold, 評価指標：mean-F1

特徴量 (次元数)	Naïve Beys (多項分布モデル)	Logistic Regression	GBDT (LightGBM)	MLP (2~4 Layers)
単語文章行列 (11799)	0.49	0.46	0.49	0.46
tf-idf (11799)	0.45	0.43	0.49	0.46
N-gram (155648)	0.48	0.47	0.49	-
N-gram + tf-idf (155648)	0.47	0.43	0.49	-

4-5. 実験結果(単語分散表現)

特徴量(次元数)	Logistic Regression	GBDT (LightGBM)	MLP (2~4 Layers)
Word2vec aver (200)	0.44	0.44	0.45
Word2vec max (200)	0.40	0.43	0.41
Word2vec hier (200)	0.39	0.41	0.41
Word2vec aver+max (400)	0.44	0.44	0.45
Fasttext aver (300)	0.47	0.46	0.49
Fasttext max (300)	0.44	0.48	0.45
Fasttext hier (300)	0.44	0.44	0.46
Fasttext aver+max (600)	0.48	0.48	0.49
Fasttext + SDV (900)	0.48	0.48	0.48

4-5. 実験結果(文章分散表現, 深層モデル)

特徴量(次元数)	Logistic Regression	GBDT (LightGBM)	MLP (2~4 Layers)
Doc2Vec PV-DBOW (300)	0.46	0.46	0.47
Doc2Vec PV-DM (300)	0.41	0.40	0.41
Doc2Vec Concat (600)	0.47	0.46	0.46

LSTM	Bi-LSTM	GRU
0.50	0.51	0.50

4. 自然言語処理

- 4-1. 単語分散表現を用いる手法
- 4-2. 文章分散表現を求める手法
- 4-3. 深層学習を用いる手法
- 4-4. 実験(データの説明)
- 4-5. 実験結果
- 4-6. 考察

4-6. 考察

- Word2vecよりFasttextの方が精度が良い。
→ subword modelによる効果があった。
- Bag-of-wordsモデルと語順考慮のモデルの精度差が小さい。
→ Twitterのような文法が曖昧なデータに対しては、
特別なアプローチが必要。文字レベルでの入力等。
- 深層モデルのEmbeddingを学習済み単語分散表現で初期化、
重みの学習をしないことで過学習を防げる。

5. まとめ

- ケプストラムやデルタケプストラム、パワーを用いて、人の音声を解析する手法を学んだ。
- 古典的なカウントベースから深層学習まで多くの統計的自然言語処理の手法について学んだ。
- 機械学習の多クラス分類手法(SVM, Logistic回帰等)を学んだ。
- 機械学習の精度検証や特徴量選択の手法を学んだ。

付録1. カウントベースの手法

1. 単語文章行列

1	1	0	0	0	まじ/嬉しい
0	1	1	1	0	私は/とても/嬉しい
0	0	0	1	1	とても/悲しい
まじ	嬉しい	私は	とても	悲しい	

高次元スパース行列

2. 単語 N-gram

「私は/全然/楽しく/ない」



N=1 : { 私は, 全然, 楽しく, ない }

N=2 : { 私は全然, 全然楽しく, **楽しくない** }

N=3 : { 私は全然楽しく, **全然楽しくない** }

付録1. カウントベースの手法

3. tf-idf による重み付け

$bow(w, d) = [\text{文章 } d \text{ 内の単語 } w \text{ の出現回数}]$

$$tf(w, d) = \frac{bow(w, d)}{[\text{文章 } d \text{ 内の単語数}]}$$

$$tf-idf(w, d) = tf(w, d) \cdot idf(w)$$

$$idf(w) = \frac{[\text{全文章数 } N]}{[\text{単語 } w \text{ が含まれる文章数}]}$$

特定の文書にしか出現しない単語やN-gramの重要度を上げる